



Promotion MLE janvier 2026

# Projet Data Science

-----

## Analyse de radiographies pulmonaires Covid-19

Alisa MALKA  
Aziz CHENNOUFI

# Edouard DUCLOY

## Sommaire

|      |                                  |    |
|------|----------------------------------|----|
| 1.   | Introduction                     | 3  |
| 1.1. | Contexte                         | 3  |
| 1.2. | Périmètre                        | 3  |
| 1.3. | Objectif                         | 3  |
| 2.   | Exploration des données          | 4  |
| 3.   | Visualisation des données        | 5  |
| 3.1. | Distribution des données         | 5  |
| 3.2. | Dimensions des données           | 6  |
| 3.3. | Aperçu des données               | 6  |
| 3.4. | Analyse des intensités de pixels | 9  |
| 3.5. | Données extrêmes                 | 11 |
| 4.   | Pré-traitement des données       | 13 |

## Table des illustrations

|            |                                                                          |    |
|------------|--------------------------------------------------------------------------|----|
| Figure 1:  | Distribution des classes                                                 | 5  |
| Figure 2:  | Distributions des dimensions des images (gauche) et des masques (droite) | 6  |
| Figure 3:  | Echantillon de données de la classe Normal                               | 7  |
| Figure 4:  | Echantillon de données de la classe COVID                                | 7  |
| Figure 5:  | Echantillon de données de la classe Lung Opacity                         | 8  |
| Figure 6:  | Echantillon de données de la classe Viral Pneumonia                      | 8  |
| Figure 7:  | Distributions des moyennes d'intensités de pixel par image               | 9  |
| Figure 8:  | Distributions des écarts-types d'intensités de pixel par image           | 10 |
| Figure 9:  | Images les plus sombres (moyenne de pixels faible)                       | 11 |
| Figure 10: | Images les plus claires (moyenne de pixels élevée)                       | 12 |
| Figure 11: | Images les moins contrastées (écart-type de pixels faible)               | 13 |
| Figure 12: | Echantillon de données pré-traitées                                      | 14 |

# 1. Introduction

## 1.1. Contexte

La pandémie de Covid-19 a mis en évidence la nécessité de développer des outils de diagnostic rapides, fiables et accessibles afin d'améliorer la prise en charge des patients. Bien que les tests PCR constituent la méthode de référence pour détecter l'infection, leur disponibilité, leur coût ou leur délai d'analyse peuvent limiter leur utilisation dans certains contextes hospitaliers. Dans ce cadre, l'analyse des radiographies pulmonaires représente une alternative intéressante pour détecter les atteintes respiratoires associées au Covid-19. Les techniques de deep learning, et plus particulièrement les modèles de computer vision, ont montré des performances importantes dans les tâches d'analyse d'images médicales. Grâce à leur capacité à extraire automatiquement des caractéristiques complexes, ces modèles peuvent être utilisés pour classifier des radiographies pulmonaires selon différentes pathologies. Plusieurs travaux de recherche récents ont démontré l'efficacité des réseaux de neurones convolutifs pour distinguer les cas Covid-19 des cas sains ou atteints d'autres pneumonies. Ce projet s'inscrit donc dans le domaine de l'intelligence artificielle appliquée à l'imagerie médicale et vise à explorer ces approches sur un jeu de données radiographiques pulmonaires.

## 1.2. Périmètre

Le projet porte sur l'analyse automatique d'images radiographiques pulmonaires issues du dataset public Covid-19 Radiography Database. Les données sont réparties en quatre catégories : *Normal*, *COVID*, *Lung Opacity*, et *Viral Pneumonia*. Chaque image est associée à un masque pulmonaire permettant d'isoler la région des poumons. Le travail réalisé couvre les étapes de préparation et d'exploration des données, le prétraitement des images ainsi que le développement de plusieurs approches de classification. Dans un premier temps, des méthodes classiques de machine learning seront étudiées à partir de caractéristiques extraites des images afin d'établir une première base de comparaison. Cette approche permettra d'évaluer les limites des méthodes traditionnelles face à des données non structurées comme les images médicales. Dans un second temps, des modèles de deep learning spécialisés en computer vision seront mis en œuvre afin d'exploiter directement l'information visuelle contenue dans les radiographies. Une attention particulière sera également portée à l'utilisation des masques pulmonaires pour segmenter les poumons et analyser l'impact de cette étape sur les performances des modèles. Enfin, le projet se limite à des radiographies pulmonaires 2D en niveaux de gris et n'inclut pas d'autres modalités d'imagerie médicale.

## 1.3. Objectif

L'objectif principal du projet est de développer un système capable de classifier automatiquement des radiographies pulmonaires selon plusieurs pathologies respiratoires,

notamment le Covid-19. Pour cela, différentes approches de computer vision et de deep learning seront étudiées et comparées afin d'identifier les architectures les plus performantes pour cette tâche. Une étape importante du projet consiste également à exploiter les masques pulmonaires disponibles afin de segmenter les poumons et de réduire l'influence des régions non pertinentes dans les images. L'étude vise ainsi à déterminer si l'utilisation des zones pulmonaires segmentées améliore la robustesse et la précision de la classification. En complément, des méthodes d'interprétabilité pourront être utilisées afin de visualiser les régions de l'image utilisées par les modèles pour prendre leurs décisions. À terme, ce travail a pour objectif d'évaluer le potentiel des méthodes d'intelligence artificielle comme outil d'aide au diagnostic médical à partir de radiographies pulmonaires.

## 2. Exploration des données

Le jeu de données est composé des 4 fichiers excel et 4 dossiers d'images, pour 4 pathologies pulmonaires :

- **Normal**
- **COVID**
- **Lung Opacity**
- **Viral Pneumonia**

Chacun des fichiers excel se compose de 4 colonnes :

- **FILE NAME** : le nom du fichier image
- **FORMAT** : le format du fichier image (valeur unique : « PNG »)
- **SIZE** : la taille de l'image (valeur unique : « 256x256 »)
- **URL** : la source du fichier image

Aucune donnée n'est manquante ou aberrante dans chacun des fichiers excel. Néanmoins, au vu du nombre de données uniques, et de leur intérêt, ces fichiers ne seront pas d'une grande utilité. Hormis la source, qui ne risque que d'apporter du biais au modèle, toutes les informations contenues dans les fichiers excel se retrouvent, de manière plus fiable, en observant les images elles-mêmes.

Enfin, chaque dossier contient lui-même 2 sous-dossiers :

- **images** : contenant les images de radiographies pulmonaires
- **masks** : contenant les masques de segmentation des poumons

Les dossiers portent le nom de la pathologie qu'ils représentent.

Les images de radiographies, dans les sous-dossiers « images » se nomment « pathologie-id.png », avec « id » une valeur entière incrémentale démarrant à 1. Ce sont des images en niveau de gris, qui sont donc bien toutes au format PNG.

Les masques, dans les sous-dossiers « masks », portent les mêmes noms que les images de radiographie auxquelles ils sont associés. Ce sont des images en noir et blanc, au format PNG également.

Pour chacune des pathologies (*Normal*, *COVID*, *Lung Opacity*, et *Viral Pneumonia*), nous disposons respectivement de 10192, 3616, 6012, et 1345 images de radiographies pulmonaires, ainsi que tout autant de masques qui leur sont associés.

## 3. Visualisation des données

### 3.1. Distribution des données

On peut observer ci-dessous la distribution des classes dans notre jeu de données.




Figure 1: Distribution des classes

La distribution des classes du jeu de données met en évidence un déséquilibre important entre les différentes catégories. La classe *Normal* représente près de la moitié des données disponibles, tandis que la classe *Viral Pneumonia* est fortement sous-représentée avec seulement 6,4 % des images. Les classes *COVID* et *Lung Opacity* disposent quant à elles d'un nombre intermédiaire d'échantillons. Ce déséquilibre peut influencer l'apprentissage des modèles en les poussant à privilégier les classes majoritaires au détriment des classes minoritaires. Dans la suite du projet, il sera donc nécessaire de mettre en place des stratégies adaptées telles que l'augmentation de données, l'utilisation de poids de classes ou encore des métriques robustes comme le F1-score afin d'évaluer correctement les performances des modèles sur l'ensemble des catégories.

### 3.2. Dimensions des données

Ci-dessous, nous pouvons observer les distributions, par classe, des dimensions des images de radiographie et des masques de segmentation.




Figure 2: Distributions des dimensions des images (gauche) et des masques (droite)

L'analyse des dimensions des images montre que la grande majorité des radiographies possède une taille homogène de 299×299 pixels, ce qui constitue un avantage important pour l'entraînement des modèles de machine learning et de deep learning. Cette homogénéité limite les étapes de redimensionnement et réduit le risque de déformation des structures anatomiques. On observe cependant une anomalie dans la classe *Viral Pneumonia*, où certaines images sont stockées au format RGB (299×299×3) alors que les autres images sont en niveaux de gris. Cette différence de nombre de canaux peut introduire des incohérences dans le pipeline de traitement et devra être corrigée lors du prétraitement en convertissant toutes les images vers un format unique en niveaux de gris.

Concernant les masques, toutes les classes présentent des dimensions homogènes de 256×256×3. Cette cohérence facilite leur utilisation dans les tâches de segmentation. Néanmoins, une différence de résolution apparaît entre les images de radiographie (299×299) et les masques (256×256). Une étape de redimensionnement des masques sera donc nécessaire avant leur application aux radiographies. De plus, les masques étant stockés sur trois canaux alors qu'ils représentent une information binaire, une conversion vers un masque binaire sera également réalisée afin de simplifier leur exploitation dans le pipeline de segmentation et de classification.

### 3.3. Aperçu des données

Ci-dessous nous pouvons observer quelques échantillons de données pour chacune des classes de notre jeu. De haut en bas, les images brutes sur la première ligne, les masques de segmentation sur la deuxième, et les images segmentées par les masques sur la troisième.




Figure 3: Echantillon de données de la classe Normal




Figure 4: Echantillon de données de la classe COVID




Figure 5: Echantillon de données de la classe Lung Opacity




Figure 6: Echantillon de données de la classe Viral Pneumonia

L'observation des échantillons du jeu de données met en évidence plusieurs éléments importants pour la suite du projet. Tout d'abord, les radiographies présentent une forte variabilité visuelle en termes de contraste, de luminosité, de positionnement du patient et de qualité d'acquisition. Certaines images contiennent également des artefacts médicaux ou



textuels (annotations, lettres, équipements hospitaliers), susceptibles d'introduire des biais dans l'apprentissage des modèles. Cette hétérogénéité justifie la mise en place d'un prétraitement adapté, notamment une normalisation des intensités et éventuellement des techniques d'amélioration du contraste comme le CLAHE.

Les masques pulmonaires apparaissent globalement cohérents et correctement alignés avec les structures anatomiques des radiographies. Leur application permet d'isoler efficacement les régions pulmonaires tout en supprimant les zones périphériques non pertinentes telles que le fond noir, les épaules ou certains artefacts externes. Cette segmentation devrait permettre aux modèles de concentrer leur apprentissage sur les zones cliniquement significatives et potentiellement améliorer leur robustesse.

Enfin, certaines différences visuelles entre les classes semblent déjà perceptibles. Les images COVID et Lung Opacity présentent fréquemment des opacités diffuses ou localisées dans les poumons, tandis que les cas normaux montrent des champs pulmonaires plus homogènes et mieux définis. Toutefois, les frontières entre certaines pathologies restent visuellement subtiles, ce qui confirme l'intérêt d'utiliser des modèles de deep learning capables d'extraire automatiquement des caractéristiques complexes à partir des images médicales.

### 3.4. Analyse des intensités de pixels

Nous pouvons observer ci-dessous les distributions, par classe, des moyennes d'intensités de pixels par image.





Figure 7: Distributions des moyennes d'intensités de pixel par image

L'analyse des distributions des moyennes d'intensité de pixels montre que les différentes classes présentent des profils de luminosité relativement proches, bien que certaines tendances se distinguent. Les classes *COVID* et *Viral Pneumonia* semblent globalement concentrées autour de moyennes plus élevées que la classe *Normal*, ce qui peut traduire une présence plus importante d'opacités pulmonaires augmentant les zones claires dans les radiographies. La classe *Lung Opacity* présente quant à elle une distribution plus étalée, ce qui suggère une plus grande variabilité des atteintes pulmonaires et des conditions d'acquisition.

Nous pouvons observer ci-dessous les distributions, par classe, des écarts-types d'intensités de pixels par image.



*Figure 8: Distributions des écarts-types d'intensités de pixel par image*

Les distributions des écarts-types mettent en évidence des différences de contraste entre les classes. Les images normales présentent une dispersion relativement concentrée, tandis que les classes pathologiques montrent des distributions plus larges, notamment pour les cas COVID. Cela peut refléter une hétérogénéité plus importante des textures pulmonaires liée aux anomalies présentes dans les poumons. On observe également un chevauchement significatif entre les distributions des différentes classes, indiquant que les statistiques globales de pixels seules ne suffisent probablement pas à séparer correctement les pathologies.

Ces observations suggèrent que des approches classiques basées uniquement sur des caractéristiques statistiques simples risquent d'être limitées pour la classification. Elles

confirment l'intérêt d'utiliser des modèles de deep learning capables d'extraire des caractéristiques spatiales et texturales plus complexes directement à partir des images. Enfin, la variabilité des distributions justifie également l'utilisation d'étapes de normalisation et de standardisation des images avant l'entraînement des modèles.

### 3.5. Données extrêmes

Ci-dessous, nous pouvons visualiser les 20 images avec les moyennes d'intensité de pixel les plus faibles (images les plus sombres).




Figure 9: Images les plus sombres (moyenne de pixels faible)

L'analyse des images présentant les moyennes d'intensité les plus faibles montre que ces radiographies sont globalement très sombres, avec parfois une grande quantité de fond noir autour de la zone anatomique utile. Certaines images apparaissent également recadrées de manière inhabituelle ou présentent des orientations différentes. Ces caractéristiques influencent fortement les statistiques globales des pixels sans nécessairement refléter l'état pathologique du patient. Cela met en évidence la nécessité de réaliser un pré traitement homogène des images, notamment via le recadrage, la normalisation des intensités et l'utilisation des masques pulmonaires pour supprimer les zones non pertinentes.


Ceci nous a poussé à analyser la distribution de ces images mal cadrées au niveau de chaque classe du dataset. En effet, s'il s'avère que ce padding noir des images concerne certaines classes contrairement à d'autres, ceci pourrait affecter l'entraînement de notre futur modèle qui risque d'associer le mal cadrage de l'image à la nature de la classe concernée.

On cherche d'abord à définir mathématiquement le caractère mal cadré de l'image afin d'étudier la distribution de ces images par classe. La statistique "zero-ratio" semble représenter correctement ce caractère puisqu'une image mal cadrée possède plusieurs pixels noirs et donc nuls.




On remarque que les images cadrées et les images *significativement* mal cadrées peuvent être discriminées par un seuil de zero-ratio d'environ 40% .

Ensuite on analyse les histogrammes ainsi que les boxplots de zero-ratio par classe



On remarque que ce type d'outliers est présent dans toutes les classes, et concerne en particulier les classes Normal, COVID et avec un degré plus élevé la classe Lung Opacity, ce qui confirme la nécessité de réaliser le recadrage afin d'éviter d'introduire un artefact à notre futur modèle. Il faudra s'assurer que les masques associés aux images transformées subissent le même redimensionnement pour obtenir des masques cohérents.


Ci-dessous, nous pouvons visualiser les 20 images avec les moyennes d'intensité de pixel les plus élevées (images les plus claires).



*Figure 10: Images les plus claires (moyenne de pixels élevée)*

Les images ayant les moyennes les plus élevées sont fortement lumineuses, parfois surexposées, avec des structures pulmonaires moins contrastées. Certaines présentent également une diffusion importante des zones blanches, possiblement liée à des opacités pulmonaires ou à des différences de conditions d'acquisition. Cette variabilité importante de luminosité confirme l'hétérogénéité du dataset et justifie l'utilisation de techniques d'amélioration du contraste et de standardisation avant l'entraînement des modèles.

Ci-dessous, nous pouvons visualiser les 20 images avec les écarts-types d'intensité de pixel les plus faibles (images les moins contrastées).



*Figure 11: Images les moins contrastées (écart-type de pixels faible)*

Enfin, les images présentant les écarts-types les plus faibles correspondent aux radiographies les moins contrastées. Les différences d'intensité entre les structures anatomiques y sont faibles, rendant les contours pulmonaires et les anomalies plus difficiles à distinguer. Ce faible contraste peut compliquer l'extraction de caractéristiques discriminantes pour des approches classiques de machine learning. Ces observations renforcent l'intérêt d'utiliser des modèles de deep learning capables d'apprendre des représentations plus robustes malgré les variations d'intensité, de contraste et de qualité d'acquisition présentes dans les données médicales.


## 4. Pré-traitement des données

Le pré-traitement des données constitue une étape essentielle du projet afin d'homogénéiser les radiographies pulmonaires et de réduire les variations liées aux conditions d'acquisition

des images. Dans un premier temps, l'ensemble des radiographies a été **converti en niveaux de gris** et **redimensionné** à une taille unique de 299×299 pixels. Cette homogénéisation des dimensions permet de garantir la compatibilité des données avec les modèles de machine learning et de deep learning utilisés par la suite. Les images ont également été **converties au format float32** afin de faciliter les opérations numériques et les étapes de normalisation.

Les masques pulmonaires fournis avec le dataset ont ensuite été pré traités de manière similaire. Initialement stockés au format 256×256×3, ils ont été **convertis en niveaux de gris** puis **redimensionnés** en 299×299 pixels à l'aide d'une interpolation adaptée aux données binaires. Une binarisation des masques a ensuite été appliquée afin d'obtenir des régions pulmonaires clairement définies.

Ensuite, un **recadrement des images** a été appliqué dans le but d'éliminer le padding présent sur le contour de certaines images. Pour cela, les images ont été binarisées en appliquant un seuillage à (0,1). Ensuite, une recherche de la boîte englobante délimitant la vraie image est réalisée en recherchant le plus petit rectangle englobant les pixels non nuls. Enfin, les images croppées sont redimensionnées par interpolation pour correspondre à la taille originale des images du dataset. Le masque associé à chaque image est redimensionné en utilisant les mêmes coefficients de redimensionnement.






**Une amélioration du contraste** a ensuite été réalisée sur les radiographies à l'aide de la méthode **CLAHE** (Contrast Limited Adaptive Histogram Equalization). Cette technique permet d'augmenter localement le contraste des images tout en limitant l'amplification excessive du bruit. Son utilisation est particulièrement adaptée aux radiographies pulmonaires, où certaines anomalies peuvent présenter de faibles variations d'intensité difficiles à distinguer sur les images originales.

**Les masques pulmonaires ont finalement été appliqués** aux radiographies afin d'isoler uniquement les régions des poumons. Cette étape permet de supprimer une grande partie des zones non pertinentes présentes dans les images, telles que le fond noir, certaines annotations ou des artefacts externes. L'objectif est ainsi de concentrer l'apprentissage des modèles sur les régions anatomiques réellement utiles au diagnostic.

Les images prétraitées ont ensuite été sauvegardées dans un nouveau répertoire afin d'être utilisées dans les étapes de modélisation et d'entraînement des modèles.

Nous pouvons observer ci-dessous quelques échantillons des images ainsi pré-traitées.



*Figure 12: Echantillon de données pré-traitées*

La normalisation finale des images ainsi que les opérations de data augmentation ne sont pas appliquées lors de la phase de prétraitement offline, mais directement au moment de l'entraînement des modèles. Cette approche dite *online* permet d'appliquer dynamiquement les transformations à chaque chargement des données dans le pipeline d'apprentissage. La

normalisation des intensités est ainsi réalisée juste avant l'entrée des images dans les modèles afin de garantir des distributions de données homogènes tout en conservant les images prétraitées sauvegardées dans un format standard exploitable. De la même manière, les opérations de data augmentation, telles que les rotations légères, translations, variations de luminosité ou modifications de contraste, sont générées aléatoirement à chaque époque d'entraînement. Cette stratégie permet d'augmenter artificiellement la diversité des données sans créer physiquement de nouvelles images sur disque, tout en réduisant le risque de surapprentissage. Elle offre également une plus grande flexibilité expérimentale pour ajuster les transformations utilisées selon les modèles évalués au cours du projet.