



Promotion MLE janvier 2026

Projet Data Science

Analyse de radiographies pulmonaires Covid-19

Alisa MALKA

Aziz CHENNOUFI

Edouard DUCLOY

Sommaire

1.	Introduction.....	3
1.1.	Contexte	3
1.2.	Périmètre.....	3
1.3.	Objectif	3
2.	Exploration des données	4
3.	Visualisation des données	5
3.1.	Aperçu des données	5
3.2.	Distribution des classes	8
3.3.	Dimensions des données.....	8
3.4.	Analyse des intensités de pixels	11
3.5.	Données extrêmes	14
4.	Pré-traitement des données	18

Table des illustrations

Figure 1: Echantillon de données de la classe Normal.....	5
Figure 2 : Echantillon de données de la classe COVID	6
Figure 3 : Echantillon de données de la classe Lung Opacity.....	6
Figure 4: Echantillon de données de la classe Viral Pneumonia	7
Figure 5: Distribution des classes	8
Figure 6: Distributions des dimensions des images (gauche) et des masques (droite).....	9
Figure 7: Distributions et boxplots des quantités de pixels en zones segmentées	10
Figure 8: Distributions et boxplots des moyennes d'intensités de pixel par image segmentée	11
Figure 9: Distributions et boxplots des écarts-types d'intensités de pixel par image segmentée	12
Figure 10: Distributions et boxplots des ratios de pixels noirs par image segmentée	13
Figure 11: Images les plus sombres (moyenne de pixels faible).....	14
Figure 12: Images les plus claires (moyenne de pixels élevée).....	15
Figure 13: Images les moins contrastées (écart-type de pixels faible)	16
Figure 14: Images les moins contrastées (écart-type de pixels faible)	17
Figure 15: Echantillon de données pré-traitées	19

1. Introduction

1.1. Contexte

La pandémie de Covid-19 a mis en évidence la nécessité de développer des outils de diagnostic rapides, fiables et accessibles afin d'améliorer la prise en charge des patients. Bien que les tests PCR constituent la méthode de référence pour détecter l'infection, leur disponibilité, leur coût ou leur délai d'analyse peuvent limiter leur utilisation dans certains contextes hospitaliers. Dans ce cadre, l'analyse des radiographies pulmonaires représente une alternative intéressante pour détecter les atteintes respiratoires associées au Covid-19. Les techniques de deep learning, et plus particulièrement les modèles de computer vision, ont montré des performances importantes dans les tâches d'analyse d'images médicales. Grâce à leur capacité à extraire automatiquement des caractéristiques complexes, ces modèles peuvent être utilisés pour classifier des radiographies pulmonaires selon différentes pathologies. Plusieurs travaux de recherche récents ont démontré l'efficacité des réseaux de neurones convolutifs pour distinguer les cas Covid-19 des cas sains ou atteints d'autres pneumonies. Ce projet s'inscrit donc dans le domaine de l'intelligence artificielle appliquée à l'imagerie médicale et vise à explorer ces approches sur un jeu de données radiographiques pulmonaires.

1.2. Périmètre

Le projet porte sur l'analyse automatique d'images radiographiques pulmonaires issues du dataset public Covid-19 Radiography Database. Les données sont réparties en quatre catégories : *Normal*, *COVID*, *Lung Opacity*, et *Viral Pneumonia*. Chaque image est associée à un masque pulmonaire permettant d'isoler la région des poumons. Le travail réalisé couvre les étapes de préparation et d'exploration des données, le prétraitement des images ainsi que le développement de plusieurs approches de classification. Dans un premier temps, des méthodes classiques de machine learning seront étudiées à partir de caractéristiques extraites des images afin d'établir une première base de comparaison. Cette approche permettra d'évaluer les limites des méthodes traditionnelles face à des données non structurées comme les images médicales. Dans un second temps, des modèles de deep learning spécialisés en computer vision seront mis en œuvre afin d'exploiter directement l'information visuelle contenue dans les radiographies. Une attention particulière sera également portée à l'utilisation des masques pulmonaires pour segmenter les poumons et analyser l'impact de cette étape sur les performances des modèles. Enfin, le projet se limite à des radiographies pulmonaires 2D en niveaux de gris et n'inclut pas d'autres modalités d'imagerie médicale.

1.3. Objectif

L'objectif principal du projet est de développer un système capable de classifier automatiquement des radiographies pulmonaires selon plusieurs pathologies respiratoires, notamment le Covid-19. Pour cela, différentes approches de computer vision et de deep

learning seront étudiées et comparées afin d'identifier les architectures les plus performantes pour cette tâche. Une étape importante du projet consiste également à exploiter les masques pulmonaires disponibles afin de segmenter les poumons et de réduire l'influence des régions non pertinentes dans les images. L'étude vise ainsi à déterminer si l'utilisation des zones pulmonaires segmentées améliore la robustesse et la précision de la classification. En complément, des méthodes d'interprétabilité pourront être utilisées afin de visualiser les régions de l'image utilisées par les modèles pour prendre leurs décisions. À terme, ce travail a pour objectif d'évaluer le potentiel des méthodes d'intelligence artificielle comme outil d'aide au diagnostic médical à partir de radiographies pulmonaires.

2. Exploration des données

Le jeu de données est composé des 4 fichiers excel et 4 dossiers d'images, pour 4 pathologies pulmonaires :

- **Normal**
- **COVID**
- **Lung Opacity**
- **Viral Pneumonia**

Chacun des fichiers excel se compose de 4 colonnes :

- **FILE NAME** : le nom du fichier image
- **FORMAT** : le format du fichier image (valeur unique : « PNG »)
- **SIZE** : la taille de l'image (valeur unique : « 256x256 »)
- **URL** : la source du fichier image

Aucune donnée n'est manquante ou aberrante dans chacun des fichiers excel. Néanmoins, au vu du nombre de données uniques, et de leur intérêt, ces fichiers ne seront pas d'une grande utilité. Hormis la source, qui ne risque que d'apporter du biais au modèle, toutes les informations contenues dans les fichiers excel se retrouvent, de manière plus fiable, en observant les images elles-mêmes.

Enfin, chaque dossier contient lui-même 2 sous-dossiers :

- **images** : contenant les images de radiographies pulmonaires
- **masks** : contenant les masques de segmentation des poumons

Les dossiers portent le nom de la pathologie qu'ils représentent.

Les images de radiographies, dans les sous-dossiers « images » se nomment « pathologie-id.png », avec « id » une valeur entière incrémentale démarrant à 1. Ce sont des images en niveau de gris, qui sont donc bien toutes au format PNG.

Les masques, dans les sous-dossiers « masks », portent les mêmes noms que les images de radiographie auxquelles ils sont associés. Ce sont des images en noir et blanc, au format PNG également.

Pour chacune des pathologies (*Normal*, *COVID*, *Lung Opacity*, et *Viral Pneumonia*), nous disposons respectivement de 10192, 3616, 6012, et 1345 images de radiographies pulmonaires, ainsi que tout autant de masques qui leur sont associés.

3. Visualisation des données

3.1. Aperçu des données

Commençons déjà par observer quelques échantillons de données pour chacune des classes de notre jeu. De haut en bas, les images brutes sur la première ligne, les masques de segmentation sur la deuxième, et les images segmentées par les masques sur la troisième.




Figure 1: Echantillon de données de la classe Normal




Figure 2 : Echantillon de données de la classe COVID




Figure 3 : Echantillon de données de la classe Lung Opacity




Figure 4: Echantillon de données de la classe Viral Pneumonia

L'observation des échantillons du jeu de données met en évidence plusieurs éléments importants pour la suite du projet. Tout d'abord, les radiographies présentent une forte variabilité visuelle en termes de contraste, de luminosité, de positionnement du patient et de qualité d'acquisition. Certaines images contiennent également des artefacts médicaux ou textuels (annotations, lettres, équipements hospitaliers), susceptibles d'introduire des biais dans l'apprentissage des modèles. Cette hétérogénéité justifie la mise en place d'un prétraitement adapté, notamment une normalisation des intensités et éventuellement des techniques d'amélioration du contraste comme le CLAHE.

Les masques pulmonaires apparaissent globalement cohérents et correctement alignés avec les structures anatomiques des radiographies. Leur application permet d'isoler efficacement les régions pulmonaires tout en supprimant les zones périphériques non pertinentes telles que le fond noir, les épaules ou certains artefacts externes. Cette segmentation devrait permettre aux modèles de concentrer leur apprentissage sur les zones cliniquement significatives et potentiellement améliorer leur robustesse.

Enfin, certaines différences visuelles entre les classes semblent déjà perceptibles. Les images COVID et Lung Opacity présentent fréquemment des opacités diffuses ou localisées dans les poumons, tandis que les cas normaux montrent des champs pulmonaires plus homogènes et mieux définis. Toutefois, les frontières entre certaines pathologies restent visuellement subtiles, ce qui confirme l'intérêt d'utiliser des modèles de deep learning capables d'extraire automatiquement des caractéristiques complexes à partir des images médicales.

3.2. Distribution des classes

On peut observer ci-dessous la distribution des classes dans notre jeu de données.




Figure 5: Distribution des classes

La distribution des classes du jeu de données met en évidence un déséquilibre important entre les différentes catégories. La classe *Normal* représente près de la moitié des données disponibles, tandis que la classe *Viral Pneumonia* est fortement sous-représentée avec seulement 6,4 % des images. Les classes *COVID* et *Lung Opacity* disposent quant à elles d'un nombre intermédiaire d'échantillons. Ce déséquilibre peut influencer l'apprentissage des modèles en les poussant à privilégier les classes majoritaires au détriment des classes minoritaires. Dans la suite du projet, il sera donc nécessaire de mettre en place des stratégies adaptées telles que l'augmentation de données, l'utilisation de poids de classes ou encore des métriques robustes comme le F1-score afin d'évaluer correctement les performances des modèles sur l'ensemble des catégories.

3.3. Dimensions des données

Ci-dessous, nous pouvons observer les distributions, par classe, des dimensions des images de radiographie et des masques de segmentation.




Figure 6: Distributions des dimensions des images (gauche) et des masques (droite)

L'analyse des dimensions des images montre que la grande majorité des radiographies possède une taille homogène de 299×299 pixels, ce qui constitue un avantage important pour leur manipulation, et l'entraînement des modèles de machine learning et de deep learning. Cette homogénéité limite les étapes de redimensionnement et réduit le risque de déformation des structures anatomiques. On observe cependant une anomalie dans la classe *Viral Pneumonia*, où certaines images sont stockées au format RGB (299×299×3) alors que les autres images sont en niveaux de gris. Cette différence de nombre de canaux peut introduire des incohérences dans le pipeline de traitement et devra être corrigée lors du prétraitement en convertissant toutes les images vers un format unique en niveaux de gris.

Concernant les masques, toutes les classes présentent des dimensions homogènes de 256×256×3. Cette cohérence facilite leur utilisation dans les tâches de segmentation. Néanmoins, une différence de résolution apparaît entre les images de radiographie (299×299) et les masques (256×256). Une étape de redimensionnement des masques sera donc nécessaire avant leur application aux radiographies. De plus, les masques étant stockés sur trois canaux alors qu'ils représentent une information binaire, une conversion vers un masque binaire sera également réalisée afin de simplifier leur exploitation dans le pipeline de segmentation et de classification.

Une fois les masques appliqués sur les images, nous pouvons observer ci-dessous les distributions et boxplots, par classe, des quantités de pixels par image en zones segmentées.

recadrage. Globalement, cette analyse confirme la cohérence des masques pulmonaires tout en révélant une certaine hétérogénéité anatomique au sein du jeu de données.

3.4. Analyse des intensités de pixels

Nous pouvons observer ci-dessous les distributions et boxplots, par classe, des moyennes d'intensités de pixels par image en zones segmentées.




Figure 8: Distributions et boxplots des moyennes d'intensités de pixel par image segmentée

L'analyse des moyennes d'intensité des pixels en zones segmentées révèle des différences notables entre les différentes classes du jeu de données. La classe *Normal* présente globalement les intensités moyennes les plus faibles, tandis que les classes pathologiques affichent des valeurs plus élevées, traduisant une présence plus importante de zones opaques dans les poumons. Les classes *COVID*, *Lung Opacity* et *Viral Pneumonia* présentent des

distributions relativement proches, bien que leurs médianes soient supérieures à celle des cas normaux. Les boxplots montrent également une dispersion plus importante pour certaines classes pathologiques, témoignant d'une plus grande variabilité des atteintes pulmonaires observées. Malgré ces différences, un chevauchement important subsiste entre les distributions, indiquant que la moyenne d'intensité ne permet pas à elle seule de distinguer parfaitement les différentes pathologies. Enfin, le faible nombre d'images aberrantes observé dans chaque classe confirme une bonne cohérence globale des données segmentées.

Nous pouvons observer ci-dessous les distributions et boxplots, par classe, des écarts-types d'intensités de pixels par image en zones segmentées.




Figure 9: Distributions et boxplots des écarts-types d'intensités de pixel par image segmentée

L'analyse des écarts-types des intensités de pixels en zones segmentées permet d'évaluer la variabilité des niveaux de gris présents dans les poumons. Les classes *COVID* et *Lung Opacity*

présentent des distributions plus étalées et des valeurs maximales plus élevées que les autres classes, ce qui traduit une plus grande hétérogénéité des textures pulmonaires. Cette observation est cohérente avec la présence d'opacités diffuses ou localisées qui augmentent les variations d'intensité au sein des poumons. À l'inverse, les classes *Normal* et *Viral Pneumonia* présentent des distributions plus resserrées autour de leur médiane, indiquant une variabilité plus homogène. Les boxplots montrent toutefois un chevauchement important entre les classes, suggérant que l'écart-type seul ne permet pas une séparation nette des pathologies. Enfin, la présence d'images aberrantes, particulièrement dans la classe *Normal*, mérite une inspection visuelle afin de vérifier si elles correspondent à des cas atypiques ou à des artefacts d'acquisition.

Enfin, nous pouvons observer ci-dessous les distributions et boxplots, par classe, des ratios de pixels noirs par image recadrée autour des zones segmentées.




Figure 10: Distributions et boxplots des ratios de pixels noirs par image segmentée

L'analyse du ratio de pixels noirs dans les images recadrées autour des zones segmentées permet d'évaluer indirectement la proportion d'espace occupée par les régions pulmonaires segmentées. Les classes *Normal*, *COVID* et *Lung Opacity* présentent des distributions relativement proches, avec des médianes comprises entre 0,50 et 0,55, indiquant une occupation similaire de l'image par les poumons. La classe *Viral Pneumonia* se distingue en revanche par des ratios significativement plus élevés, traduisant des régions pulmonaires segmentées généralement plus petites relativement à la taille de l'image recadrée. Cette différence peut s'expliquer par des caractéristiques anatomiques particulières des patients ou par des variations dans les conditions d'acquisition des radiographies. Les distributions demeurent toutefois largement chevauchantes, ce qui suggère que cette variable ne constitue pas un critère discriminant suffisant à elle seule. Enfin, le faible pourcentage d'images aberrantes observé dans chaque classe témoigne d'une bonne cohérence globale du processus de segmentation et de recadrage.

3.5. Données extrêmes

Ci-dessous, nous pouvons visualiser les 5 images segmentées avec les moyennes d'intensité de pixel les plus faibles (images les plus sombres), par classe.




Figure 11: Images les plus sombres (moyenne de pixels faible)

Les images présentant les plus faibles moyennes d'intensité sont globalement caractérisées par des poumons relativement sombres, indiquant une faible proportion de zones radio-opaques visibles. Cette tendance est particulièrement marquée pour les classes *Normal* et *COVID*. Quelques cas atypiques apparaissent dans la classe *Lung Opacity*, avec des masques partiels ou des artefacts pouvant influencer les statistiques calculées. Enfin, les images de *Viral Pneumonia* conservent des moyennes plus élevées que les autres classes, même parmi les valeurs les plus faibles de leur catégorie, suggérant des différences de distribution des intensités au sein des régions pulmonaires.

Ci-dessous, nous pouvons visualiser les 5 images segmentées avec les moyennes d'intensité de pixel les plus élevées (images les plus claires), par classe.



Figure 12: Images les plus claires (moyenne de pixels élevée)

Les images présentant les plus fortes moyennes d'intensité sont caractérisées par des poumons globalement très clairs, traduisant une proportion importante de pixels de forte intensité au sein des régions segmentées. Cette observation peut être liée à la présence d'opacités pulmonaires étendues, mais également à des différences de contraste ou d'exposition lors de l'acquisition des radiographies. Les images des classes *COVID* et *Lung Opacity* figurent logiquement parmi les valeurs les plus élevées, certaines présentant des

régions pulmonaires presque uniformément claires. Cependant, la présence d'images de la classe *Normal* parmi ces extrêmes montre que des facteurs techniques peuvent également influencer fortement cette métrique. Cette analyse confirme que la moyenne d'intensité apporte une information pertinente sur l'aspect global des poumons, mais qu'elle ne permet pas à elle seule de distinguer clairement les différentes classes.

Ci-dessous, nous pouvons visualiser les 5 images segmentées avec les écarts-types d'intensité de pixel les plus faibles (images les moins contrastées), par classe.




Figure 13: Images les moins contrastées (écart-type de pixels faible)

Les images présentant les écarts-types les plus faibles correspondent aux radiographies les moins contrastées. Les différences d'intensité entre les structures anatomiques y sont faibles, rendant les contours pulmonaires et les anomalies plus difficiles à distinguer. Ce faible contraste peut compliquer l'extraction de caractéristiques discriminantes pour des approches classiques de machine learning. Ces observations renforcent l'intérêt d'utiliser des modèles de deep learning capables d'apprendre des représentations plus robustes malgré les variations d'intensité, de contraste et de qualité d'acquisition présentes dans les données médicales.

Ci-dessous, nous pouvons visualiser les 5 images segmentées avec les écarts-types d'intensité de pixel les plus élevés (images les plus contrastées), par classe.




Figure 14: Images les moins contrastées (écart-type de pixels faible)

Les images présentant les écarts-types les plus élevés se distinguent par une forte hétérogénéité des intensités au sein des poumons. Elles contiennent généralement des zones très claires et très sombres coexistant dans la même image, ce qui augmente fortement la dispersion des niveaux de gris. Cette variabilité peut être liée à la présence d'opacités localisées, de structures anatomiques fortement contrastées ou d'artefacts d'acquisition. Certaines images montrent également des objets externes ou des anomalies visibles susceptibles d'accentuer les contrastes observés. Contrairement aux images à faible écart-type, les détails pulmonaires et les textures sont ici nettement plus marqués. La présence de telles images dans toutes les classes confirme que l'écart-type mesure principalement la richesse des variations d'intensité et non directement la nature de la pathologie représentée.

4. Pré-traitement des données

Le prétraitement des données constitue une étape essentielle du projet afin d'homogénéiser les radiographies pulmonaires et de réduire les variations liées aux conditions d'acquisition des images. Dans un premier temps, l'ensemble des radiographies a été **converti en niveaux de gris** et **redimensionné** à une taille unique de 299×299 pixels. Cette homogénéisation des dimensions permet de garantir la compatibilité des données avec les modèles de machine learning et de deep learning utilisés par la suite. Les images ont également été **converties au format float32** afin de faciliter les opérations numériques et les étapes de normalisation.

Les masques pulmonaires fournis avec le dataset ont ensuite été prétraités de manière similaire. Initialement stockés au format 256×256×3, ils ont été **convertis en niveaux de gris** puis **redimensionnés** en 299×299 pixels à l'aide d'une interpolation adaptée aux données binaires. Une binarisation des masques a ensuite été appliquée afin d'obtenir des régions pulmonaires clairement définies.

Les masques pulmonaires ont ensuite été appliqués aux radiographies afin d'isoler uniquement les régions des poumons. Cette étape permet de supprimer une grande partie des zones non pertinentes présentes dans les images, telles que le fond noir, certaines annotations ou des artefacts externes. L'objectif est ainsi de concentrer l'apprentissage des modèles sur les régions anatomiques réellement utiles au diagnostic.

Ensuite, un **recadrage des images** a été appliqué dans le but de maximiser la quantité d'information pertinente présente dans chaque image. Pour cela, le padding présent tout autour des zones segmentées a été supprimé, puis chaque image a été redimensionnée à sa taille initiale de 299×299, tout en conservant les proportions dimensionnelles des zones segmentées afin de ne pas distordre l'information initiale.

Enfin, **une amélioration du contraste** a été réalisée sur les images à l'aide de la méthode **CLAHE** (Contrast Limited Adaptive Histogram Equalization). Cette technique permet d'augmenter localement le contraste des images tout en limitant l'amplification excessive du bruit. Son utilisation est particulièrement adaptée aux radiographies pulmonaires, où certaines anomalies peuvent présenter de faibles variations d'intensité difficiles à distinguer sur les images originales.

Les images prétraitées ont ensuite été sauvegardées dans un nouveau répertoire afin d'être utilisées dans les étapes de modélisation et d'entraînement des modèles.

Nous pouvons observer ci-dessous quelques échantillons des images ainsi prétraitées, ainsi que le processus de pré-traitement.




Figure 15: Echantillon de données pré-traitées

La normalisation finale des images ainsi que les opérations de data augmentation ne sont pas appliquées lors de la phase de prétraitement offline, mais directement au moment de l'entraînement des modèles. Cette approche dite *online* permet d'appliquer dynamiquement les transformations à chaque chargement des données dans le pipeline d'apprentissage. La normalisation des intensités est ainsi réalisée juste avant l'entrée des images dans les modèles afin de garantir des distributions de données homogènes tout en conservant les images prétraitées sauvegardées dans un format standard exploitable. De la même manière, les opérations de data augmentation, telles que les rotations légères, translations, variations de luminosité ou modifications de contraste, sont générées aléatoirement à chaque époque

d'entraînement. Cette stratégie permet d'augmenter artificiellement la diversité des données sans créer physiquement de nouvelles images sur disque, tout en réduisant le risque de surapprentissage. Elle offre également une plus grande flexibilité expérimentale pour ajuster les transformations utilisées selon les modèles évalués au cours du projet.